

Configuración de Master en Python3.6-Veny, tres Worker en Contenedores Docker y con Jupyter

Doker-Spark-Jupyter-V:02

Estos Apuntes se basan un laboratorio (Que iré escalando) de Apache-Spark y Docker y controlando por PySpark, Jupyter-Notebook. Probando diferentes configuraciones de Pytho-Venv, Docker, en Cluster esta la llamare V:02.

En esta ocasión usare un *portátil Host* el cual ejecuta sus nodo *Master, Jupter, SparkSession* y un *Server-Ubuntu:20.04* en el cual irán alojados los *Worker1,Worker2,Worker3*,

Tenemos un entorno virtual *Python3.6-Venv*, ya creado anteriormente como un ecosistema con *Apache-Spark*, *PySpark*, *Jupyter*.

Necesitamos una Imagen de Docker ya creada para tal fin, las tenemos el el repositorio de Docker o la generamos nosotros , que es lo que aremos : empezamos por **crear un contenedor Docker** a partir de una imagen de Docker (**Ubuntu:18.04**) la usaremos como base de nuestro contenedor la cual modificaremos para crear nuestro **contenedor** y apartir de este crear **nuestra imagen** de la cual crearemos los Workers que necesitemos. Tenemos diferentes formas de abordar el tema , usar una **imagen del repositorio oficial de Docker** , usar o crear un **Dockerfile** o hacerlo manualmente , nosotros usaremos esta ultima.

Creacion de una **Imagen Docker** a partir de un Contenedor

Crear un contenedor Docker lo llamaremos (spark_docker)
root@serve--hp8100:/# docker run -it --name spark_docker -m 1024M --cpus 1 ubuntu
root@c59e3ef5557f:/#

Deshabilitar el **modo interactivo** ¿para que no pregunte? **root@c59e3ef5557f:/# export DEBIAN_FRONTEND=noninteractive**

Instalar las dependencias(Java, Python y Nano)

root@c59e3ef5557f:/# apt update && apt install -y openjdk-8-jdk python nano

Descarga Spark: (descomprimir el fichero.tgz)-(crear)Mover a la carpeta /spark root@serve--hp8100:/# curl -O https://archive.apache.org/dist/spark/spark-3.1.1/spark-3.1.1-bin-hadoop3.2.tgz

root@serve--hp8100:/# tar xvf spark-3.1.1-bin-hadoop3.2.tgz

Copiar el paquete entero de Apache Spark < ID_CONTENEDOR > /opt del cotenedor root@juan-Aspire-ES1-512:/# docker cp spark-3.1.1-bin-hadoop3.2 c59e3ef5557f:/opt

Renombra Carpeta

root@c59e3ef5557f:/opt# mv spark-3.1.1-bin-hadoop3.2 spark

Crea un enlace simbólico

root@c59e3ef5557f:/opt# ln -s /opt/spark/sbin

Establecer entorno de Spark(Abra su archivo de configuración de **bashrc**)Activa los cambios

root@1bf0b87d3b85:/# nano ~/.bashrc

export SPARK_HOME=/opt/spark

export PATH=\$SPARK HOME/bin:\$PATH

root@1bf0b87d3b85:/# source ~/.bashrc#

Crear una **Imagen** a partir de un **Contenedor**

CONTAINER ID IMAGE COMMAND CREATED STATUS PORTS NAMES 40c9653c010c ubuntu:18.04 "bash" 24 hours ago Exited (127) 24 hours ago spark_docker

root@serve--hp8100:/# docker commit 40c9653c010c spark_docker:21.07
sha256:5bb39b6744e6d287621bdd42bb3c8cb2d9f65f73c98b3d0b5d47b1e791529d36

root@serve--hp8100:/# docker images

spark docker 21.07 **5bb39b6744e6** About a minute ago 783MB.

Arracamos Paython-Venv – Spark-Master


Disponemos de un entorno virtual Python3.6-Venv, ya creado anteriormente como un ecosistema con **Apache-Spark**, **PySpark**, **Jupyter**.en el **portátil Host**

Levantamos entorno virtual venv (Activate)-(Deactivate)

root@juan-Aspire-ES1-512:/# source my_pyspark/bin/activate (my_pypark) root@juan-Aspire-ES1-512:/# deactivate

Arrancamos Spark ejecuta sus nodos Master my-portatil-Host 192.168.1.36 (my_pyspark) root@juan-Aspire-ES1-512:/# ./spark/sbin/start-master.sh -h 192.168.1.36

Arranca interface-Wed-**Spar-Master** http://127.0.0.1:8080/



Continuamos con la creación del (Cluster de tres Worker)

Creamos el Contenedor Worker-1

root@serve--hp8100:/# docker run -it --name worker-1 -m 1024M --cpus 1 spark_docker:21.07 root@ef00c9ebbb14:/#

CONTAINER ID IMAGE COMMAND CREATED STATUS PORTS NAMES *ef00c9ebbb14* spark_docker:21.07 "bash" About a minute ago Up About a minute worker-1

Arrancamos Worker-1

root@ef00c9ebbb14:/opt# ./spark/sbin/start-worker.sh spark://192.168.1.36:7077
starting org.apache.spark.deploy.worker.Worker, logging to /opt/spark/logs/spark-org.apache.spark.deploy.worker.Worker-1-ef00c9ebbb14.out
root@ef00c9ebbb14:/opt#

Creamos el Contenedor Worker-2

root@serve--hp8100:/# docker run -it --name worker-2 -m 1024M --cpus 1 spark_docker:21.07 root@5cfbc7c97119:/#

CONTAINER ID	IMAGE	COMMAN	ND CREATED	STATUS	PORTS	NAMES
5cfbc7c97119	spark_docker:21.07	"bash"	5 minutes ago	Up 5 minutes		worker-2
ef00c9ebbb14	spark_docker:21.07	"bash"	23 minutes ago	Up 23 minute	S	worker-1

root@5cfbc7c97119:/opt# ./spark/sbin/start-worker.sh spark://192.168.1.36:7077

starting org.apache.spark.deploy.worker.Worker, logging to /opt/spark/logs/spark-org.apache.spark.deploy.worker.Worker-1-**5cfbc7c97119**.out

root@5cfbc7c97119:/opt#

Creamos el Contenedor Worker-3


root@serve--hp8100:/# docker run -it --name worker-3 -m 1024M --cpus 1 spark_docker:21.07 root@eb42b6da656f:/#

CONTAINER ID IMAGE	COMMAN	D CREATED	STATUS	PORTS	NAMES
eb42b6da656f spark_docker:21.07	"bash"	About a minute ago	Up About a min	ute	worker-3
5cfbc7c97119 spark_docker:21.07	"bash"	23 minutes ago	Up 23 minutes		worker-2
ef00c9ebbb14 spark_docker:21.07	"bash"	41 minutes ago	Up 41 minutes		worker-1

root@eb42b6da656f:/opt# ./spark/sbin/start-worker.sh spark://192.168.1.36:7077

starting org.apache.spark.deploy.worker.Worker, logging to /opt/spark/logs/spark-org.apache.spark.deploy.worker.Worker-1-eb42b6da656f.out

root@eb42b6da656f:/opt#



Arrancamos un Jupyter-Notebook

(my_pyspark) root@juan-Aspire-ES1-512:/# jupyter notebook --allow-root

```
(my_pyspark) root@juan-Aspire-ES1-512:/# jupyter notebook --allow-root
[I 10:03:17.331 NotebookApp] Serving notebooks from local directory: /
[I 10:03:17.331 NotebookApp] Jupyter Notebook 6.4.0 is running at:
[I 10:03:17.331 NotebookApp] http://localhost:8888/?token=17cafcaaad4e02e72275b1332a26fed7334588b6df7e3c92
[I 10:03:17.331 NotebookApp] or http://127.0.0.1:8888/?token=17cafcaaad4e02e72275b1332a26fed7334588b6df7e3c92
[I 10:03:17.331 NotebookApp] Use Control-C to stop this server and shut down all kernels (twice to skip confirmation).
[C 10:03:17.388 NotebookApp]
To access the notebook, open this file in a browser:
```


http://127.0.0.1:8888/?token=17cafcaaad4e02e72275b1332a26fed7334588b6df7e3c92


Crear una aplicación Spark y comenzar: pegando el siguiente script en una celda de Jupyter import findspark

findspark.init()

import pyspark


sc = pyspark.SparkContext(master='spark://192.168.1.36:7077',appName='myspark')





Pagina 5 Juan_Maria_Morera, Analista de Datos

192.168.1.36:4040 como vemos y arancado la *Consola PySpark* en nuestro *Jupyter* hemos dado la orden de (import pyspark), arrancamos (SparkContext) sc.



En esta captura tenemos los Status, IP, memoria etc en Executurs.

Recapitulando: activamos el entorno virtual **Python3.6-Venv**, activamos el (**start-master.sh**) en el Host. En nuestro **Servidor-Ubuntu** con tres **contenedor Docker** activamos los **tres Worker** situado cada contenedor (**start-worker.sh**)

En nuestro navegador Wed *http://127.0.0.1:8080/* el cual nos dara la *URL: spark://192.168.1.36:7077* y información de nuestros workers sintuados en los tres contenedores y los recurso de nuestro entorno .

Arrancaremos nuestra **IDE** favorita en mi caso *Jupyter-Notebook*, **import findspark** y **pyspark** y ejetutamos un pequeño *script* para confirmar la **interacciona con Spark** a traves de *API-PySpark* lo cual podemos comprobar en *Spark context* Web UI available at http://192.168.1.36:4040

Usar **Docker** y **Python-Venv** se trata de aislar todos estos procesos de la maquinas Host o Server con un entorno mas seguro y relativamente (fácil de usar) esto es el motivo de estos apuntes espero cumplan su objetivos .